

EV Challenge — GoodWe · Sprint 03

Evidência da memória da conversa

FIAP · Prompt and Artificial Intelligence · 2026.2 · Prof. Jorge Luiz Gomes · Turma 1CCPH

Documento: docs/evidencia_memoria.md (versão em PDF). Comando usado: python demo_memoria.py

1. O que testamos

O enunciado pede que a memória funcione em pelo menos 3 turnos. Fizemos uma conversa de 4 perguntas na mesma sessão, com o prompt v3 e o modelo gpt-oss:120b. A 4ª pergunta testa se o bot lembra do que foi dito na 1ª. Repetimos a conversa com dois limites de memória, medidos em tokens (pedaços de palavras).

As 4 perguntas:

1. “Meu posto tem 3 carregadores GW11K-HCA-20 e o disjuntor geral é limitado.”
2. “O que o controle dinâmico de carga faz nessa situação?”
3. “E se um deles mostrar uma luz vermelha piscando?”
4. “Qual era o modelo dos carregadores que eu citei no início da conversa?” ← testa a memória do turno 1

2. Execução A: limite de 1.000 tokens (o bot esqueceu)

Turno	Memória depois da resposta	Texto enviado ao modelo	Tempo
1	2 mensagens · 603 tokens	4.690 tokens	3,7 s
2	4 mensagens · 749 tokens	5.282 tokens	1,1 s
3	2 mensagens · 862 tokens (os turnos 1 e 2 foram apagados)	5.429 tokens	3,4 s
4	4 mensagens · 962 tokens	5.544 tokens	4,1 s

Resposta real no turno 4: “Não foi mencionado nenhum modelo de carregador na sua mensagem anterior. Caso precise de informações sobre os modelos disponíveis (por exemplo, GW7K-HCA-20, GW11K-HCA-20 ou GW22K-HCA-20), [...]”

O que isso mostra: quando a memória passou de 1.000 tokens, as mensagens mais antigas foram apagadas e o bot esqueceu o turno 1. Ou seja, o limite funciona, mas 1.000 tokens é pouco para respostas de 400 a 800 tokens.

3. Execução B: limite de 3.000 tokens (o bot lembrou)

Turno	Memória depois da resposta	Texto enviado ao modelo	Tempo
1	2 mensagens · 155 tokens	4.690 tokens	2,3 s
2	4 mensagens · 400 tokens	4.834 tokens	2,1 s
3	6 mensagens · 1.224 tokens	5.080 tokens	4,1 s
4	8 mensagens · 1.268 tokens	5.910 tokens	0,9 s

Resposta real no turno 4: “Os carregadores citados são do modelo **GW11K-HCA-20**.”

O que isso mostra: com 3.000 tokens o bot recuperou a informação do turno 1. O custo é que o texto enviado cresce a cada turno (de 4.690 para 5.910 tokens), porque o histórico é reenviado inteiro.

4. Conclusão

- A memória por sessão funciona em 4 turnos, com limite de tokens que realmente apaga as mensagens antigas (execução A).
- Limite maior significa mais contexto, mas também mais tokens por pergunta.
- As respostas mudam de uma execução para outra (temperature 0,2, sem semente fixa): o turno 1 foi longo na execução A e curto na B.

As respostas completas do bot foram resumidas aqui; as medidas e o turno 4 são as saídas reais. Na execução A, a linha do usuário do turno 4 saiu cortada na cópia do terminal e foi restaurada a partir do arquivo demo_memoria.py.