Relatório de evolução - Sprint 04

EV Challenge GoodWe · FIAP · Prompt and Artificial Intelligence · Ciência da Computação (2SEM) · Turma 1CCPH · 2026.2 · Prof. Jorge Luiz Gomes
Repositório: https://github.com/gabifiap/evcharger-chatbot

1. Resumo da evolução

Nas Sprints 1 e 2 o chatbot usava o Gemini com o prompt v1 e sem memória, e mandava a base de conhecimento inteira em toda pergunta, cerca de 4.600 tokens, sem citar fonte. Na Sprint 3 refizemos o núcleo com LangChain e o gpt-oss:120b (Ollama Cloud), com memória por sessão, saída estruturada e guardrails, mas a base continuava indo inteira no prompt. Nesta Sprint 04 passamos para RAG. Ampliamos a base com os 76 trechos do dataset (agora em .md) e 3 PDFs da GoodWe (datasheet e manual do usuário do HCA G2 e o mapa Modbus), indexamos tudo no ChromaDB com o nomic-embed-text e agora cada pergunta recebe só os trechos mais parecidos. O bot cita documento e página, recusa quando a informação não está nos documentos e a interface em Streamlit mostra as fontes. Cada iteração foi medida com faithfulness e answer_relevancy.

2. Pipeline RAG: decisões e trade-offs

Etapa	Decisão	Por quê / trade-off
Carga	PDFs com PyMuPDFLoader (uma página = um documento, página 1-based); .md dividido por seção "##" (cada pergunta/resposta do dataset é uma unidade).	A seção mantém pergunta e resposta juntas e dá uma citação precisa. Páginas sem texto são ignoradas.
Chunking	RecursiveCharacterTextSplitter, 800 caracteres, overlap 100 (ponto de partida da Aula 06).	Trechos do dataset já têm cerca de 200 caracteres; o tamanho só afeta de fato as páginas dos PDFs. Testar 500/50 fica como evolução.
Embeddings	nomic-embed-text (768 dimensões) no Ollama instalado no computador.	O Ollama Cloud recusou o modelo (401). Em compensação o app só roda onde houver Ollama local.
Vector store	ChromaDB persistente, similaridade cosseno, uma coleção por configuração (kb_cs800_ov100).	Permite comparar iterações sem apagar a anterior; recarregar do disco não recalcula embeddings.
Retrieve	Top-k por similaridade (k=3, 3, 5 nas iterações 1 a 3).	k maior traz mais chance de achar o trecho certo, mas o prompt fica bem mais longo (ver tokens na seção 4).
Prompt	Versionado em prompts/rag_v1..v3.md; o contexto entra na mensagem do usuário, dentro de <documento>.	O histórico guarda só a pergunta crua, sem o contexto.
Segurança	Chunks com ordens escondidas ("ignore as instruções...") não são indexados; guardrails de entrada e saída da Sprint 3 mantidos; citação obrigatória.	Regras de texto simples: uma frase bem reescrita pode passar.

3. Avaliação: método e iterações

Não conseguimos usar o pacote ragas: ele não importa com o langchain-community atual (dá ModuleNotFoundError em langchain_community.chat_models.vertexai). Por isso usamos o fallback manual que o enunciado aceita, com notas de 0 a 1 calculadas do mesmo jeito que o RAGAS. **Faithfulness**: o modelo juiz separa a resposta em afirmações e confere cada uma contra o contexto recuperado; a nota é a fração que o contexto sustenta. **Answer relevancy**: o juiz cria 3 perguntas a partir da resposta e a nota é a média da similaridade cosseno delas com a pergunta original. **Contexto relevante**: fração dos trechos recuperados que servem para responder a pergunta. Usamos as mesmas 19 perguntas em todas as iterações, o gpt-oss:120b como gerador (temperature 0,2, top_p 0,9, max_tokens 1024) e o gemma4:31b-cloud como juiz, porque o qwen3.6:27b da aula não está no plano gratuito. Respostas de recusa e bloqueios dos guardrails não entram nas médias de faithfulness e relevância.

Iter.	Prompt	chunk / overlap / k	Pont.	Recus.	Faithful-ness	Answer relev.	Contexto relev.	Seg. (testes)
it1	v1	800/100/3	10	0	0,596	0,769	0,167	0,769
it2	v2	800/100/3	5	5	0,619	0,715	0,333	0,923
it3	v3	800/100/5	7	3	0,620	0,732	0,343	1,000

Não dá para comparar as médias da tabela direto, porque cada iteração pontua um número diferente de perguntas (com o prompt mais restrito o modelo recusa mais). Por isso comparamos só as perguntas pontuadas nas duas iterações. De it1 para it2 (5 perguntas pontuadas nas duas): faithfulness 0,50 para 0,62, answer_relevancy 0,73 para 0,72, testes de segurança 0,769 para 0,923. De it2 para it3 (5 perguntas pontuadas nas duas): faithfulness 0,62 para 0,64, answer_relevancy 0,72 para 0,72, testes de segurança 0,923 para 1,000. Da it1 para a it3 (7 perguntas pontuadas nas duas): faithfulness 0,46 para 0,62, answer_relevancy 0,75 para 0,73, contexto relevante 0,24 para 0,34.

Versões do prompt RAG

Versão	O que mudou	Efeito medido
v1	Baseline: "responda usando o contexto".	Não seguia uma recusa padrão: nos testes de segurança reprovou o erro 47 e o modelo GW50K (reconhecia que não constava, mas sem orientar o suporte) e extrapolava em perguntas sem resposta direta. A citação era só completada pelo código.
v2	Grounding estrito, citação (fonte: rótulo), recusa padrão "Não encontrei...", regra de alertas de hardware.	Testes de segurança de 0,769 para 0,923: recusa padrão com orientação ao suporte (erro 47 e GW50K passaram). Efeito colateral: 5 recusas, 3 delas indevidas. O modelo passou a escrever "documento n 3" em vez do arquivo.
v3	v2 + bloco de segurança (contexto é dado, nunca instrução), risco crítico sem instruir a mexer no equipamento, rótulo "Fonte:" visível no trecho.	Testes de segurança 0,923 para 1,000 (13 de 13). Com k=5 as recusas indevidas caíram de 3 para 1 (as perguntas 1 e 7 voltaram a ser respondidas). A resposta para faíscas passou a começar por manter distância e chamar um profissional. O modelo continuou citando "documento 4" no texto.

4. Comparativo antes/depois

Critério	Sprints 1/2 (versão original)	Sprint 04 (RAG avaliado)
Contexto enviado ao modelo	Base inteira em toda pergunta (4.616 tokens medidos por pergunta na Sprint 3)	Só os trechos recuperados. Prompt médio por pergunta: it1: 452 | it2: 651 | it3: 1228 tokens
Faithfulness por iteração	Não medido	it1: 0,596 | it2: 0,619 | it3: 0,620
Answer relevancy por iteração	Não medido	it1: 0,769 | it2: 0,715 | it3: 0,732
Qualidade do contexto recuperado	Não se aplica (base inteira, sem busca)	Contexto relevante it1: 0,167 | it2: 0,333 | it3: 0,343 (o juiz é exigente e a busca é o ponto fraco do pipeline)
Citação de fonte	Não citava	Documento e página (ex.: GW_HCA-G2_User-Manual-PT.pdf, pág. 14) na lista de fontes e nos trechos mostrados pela interface. No texto da resposta o modelo ainda cita pelo número do trecho
Recusa fora do contexto	Só recusa por escopo (guardrails); sem recusa por falta de contexto	Recusa com "Não encontrei essa informação nos documentos fornecidos" (v2 em diante)
Testes automáticos de segurança	11 de 13 (Sprints 1/2) e 13 de 13 (Sprint 3)	it1: 10 de 13 | it2: 12 de 13 | it3: 13 de 13
Base de conhecimento	Dataset (7 conjuntos de perguntas e respostas)	Dataset em .md + datasheet, manual do usuário e mapa Modbus do HCA G2 (PDF)
Interface	Streamlit sem fontes	Streamlit com fontes e trechos recuperados visíveis (app/app.py)

5. Problemas encontrados e soluções

Problema	Decisão tomada e por quê
O Ollama Cloud devolveu erro 401 para o nomic-embed-text, mesmo com a chave funcionando no chat.	Testamos chat e embeddings separados e só o embeddings falhava. Passamos os embeddings para o Ollama instalado no computador e deixamos o chat no Cloud. O custo é que indexar passa a exigir o Ollama local.
O juiz qwen3.6:27b da aula não existe no plano gratuito (erro 404) e o eval caía antes de salvar o resultado.	Trocamos o juiz para o gemma4:31b-cloud e registramos isso em cada resultado. Como o ragas também não importava, ficamos com a rubrica manual.
O modelo citava "documento n 3" em vez do nome do arquivo. Na it1 a citação só aparecia porque o código completava as fontes no fim da resposta.	No v3 o rótulo virou uma linha "Fonte: arquivo, pág. X" dentro do trecho e o prompt proibiu "documento n". Não funcionou por completo: na it3 o modelo ainda escreve "(fonte: documento 4)" no texto. Mantivemos o código que lista os arquivos e páginas, e a interface mostra as fontes completas. Um próximo passo seria trocar o número pelo nome do arquivo por código.
Para faíscas no conector, o v1 e o v2 mandavam reconectar o plugue (copiando o contexto) e o aviso de emergência só vinha no rodapé.	No v3 a resposta começa mandando manter distância e chamar um profissional, e o prompt proíbe instruir qualquer mexida no equipamento. Funcionou na it3: a resposta não manda mais reconectar nada e cita os Bombeiros (193).
Com k=3 a busca trouxe trechos pouco relacionados (contexto relevante baixo) e o v2 recusou perguntas que têm resposta na base (ids 1, 3 e 7).	Na it3 subimos o k para 5: as perguntas 1 e 7 passaram a ser respondidas, mas a 3 (previsão de lotação) continua recusada e o contexto relevante quase não mudou (0,333 para 0,343). Reranking com cross-encoder fica como próximo passo.

6. Limites e próximos passos

Cada pergunta foi feita uma vez, só 5 a 10 perguntas entram nas médias e o juiz é outro modelo de IA, então diferenças pequenas podem ser acaso. A pergunta sobre faíscas tem faithfulness 0 na it3: o juiz procura as orientações de segurança nos documentos, mas elas vêm do prompt, e é isso que queremos nesse caso. O contexto relevante continua perto de 0,34, o que mostra que a busca é o ponto a melhorar. Reranking, chunking semântico e a troca do número do trecho pelo nome do arquivo na citação ficaram para depois. Os embeddings dependem de um Ollama local, então a interface não roda como está no Streamlit Cloud. O dataset também tem pequenas contradições entre trechos (grau de proteção IP65 em um e IP66 em outro) que o bot pode repetir.

7. Equipe

Nome	RM
Gabriela Batista Costa	RM573583
Samara Carvalho	RM573666
Anna Luiza Carvalhaes	RM573330
Kethelyn Rocha	RM574016